

湖南大学

毕业论文(设计)开题报告

(全日制本科生)

基于大语言模型的分子进化优化

课 题 名 称

器

课 题 类 别

设计 ☐

论文



论文(设计)

题 目

学 生 所 在

计算机科学与技术、计算机科学

专 业、班 级

与技术 2202

学

生

杜森源

学

号

202208010211

指 导 教 师

刘益萍

二〇二六年一月

开题报告填写要求

一、开题报告是毕业论文（设计）答辩委员会对学生答辩资格审查的内容之一。此报告应在指导教师指导下，由学生在毕业论文（设计）工作前期完成，经指导教师签署意见及所在专业审查后生效。

二、开题报告在教学信息化服务平台填写后导出打印，打印时必须是双面打印，可以按需加页。开题报告填写完成后应及时交给指导教师签署意见。

三、开题报告内有关“学院”、“专业”等名称的填写，应写中文全称；学生的“学号”必须填写完整。

四、学生毕业后开题报告随同毕业论文（设计）一同归档。

一、本课题研究（设计）的目的：

本研究旨在探索大语言模型在进化算法框架下应用于分子属性优化任务的可行性与有效性。具体而言，研究将聚焦于优化分子的 QED（药物相似性）、DRD2（多巴胺 D2 受体结合活性）、GSK3 β （糖原合成酶激酶-3 β 抑制活性）和 JNK3（c-Jun N-末端激酶 3 抑制活性）等关键属性指标。通过将 LLM 作为优化器嵌入进化算法流程，本研究期望实现以下目标：

提升分子属性优化效率：利用 LLM 的文本生成与推理能力，替代传统进化算法中依赖专家规则的交叉与变异操作，提高搜索效率与优化精度；

探索无训练优化路径：通过精心设计的提示词与采样策略，引导通用 LLM 完成分子属性优化任务，避免对模型进行微调或训练，降低计算成本；

推动 LLM 在计算化学中的应用：验证 LLM 在分子设计与属性预测中的潜力，为药物发现与材料设计提供一种新颖、可解释的智能优化工具；

培养学生综合实践能力：通过框架搭建、策略设计与实验分析，提升学生在人工智能、优化算法与跨学科应用方面的创新能力。

二、研究（设计）现状和发展趋势：

分子优化是化学信息学、药物发现与材料设计领域的核心任务之一，其目标是高效地在巨大而复杂的化学空间中寻找具有特定理想性质（如高生物活性、低毒性、优良的药代动力学特性等）的分子结构。随着人工智能技术的飞速发展，尤其是深度学习与大语言模型的突破，分子优化领域的研究范式正经历着深刻的变革。本部分将从传统进化算法、深度学习驱动分子生成与优化、以及大语言模型在分子优化中的新兴应用三个层面，系统梳理研究现状，并分析其发展趋势，为本研究提供坚实的背景与方向指引。

传统进化算法在分子优化中的应用与局限

传统的分子优化方法主要依赖于进化算法，包括遗传算法、差分进化、粒子群优化等。这些算法模拟自然进化过程，通过选择、交叉（重组）、变异等操作，在由分子结构构成的种群中进行迭代搜索，以期逐步提升适应度函数（通常为目标属性的预测值或评分）定义的分子性能。

在分子优化场景中，分子通常被编码为字符串或图结构。传统的交叉与变异操作依赖于专家精心设计的规则。例如，交叉操作可能是在两个 SMILES 字符串的随机位置进行切割和交换片段；变异操作则可能涉及随机替换原子、改变键类型、或插入/删除官能团等。这些规则虽然直观，但存在显著局限性：

1. 规则依赖性与设计负担：算法性能高度依赖于预设的规则库。设计一套能够覆盖复杂化学空间、同时保证生成分子化学合理性与合成可及性的规则，需要深厚的化学专业知识，且过程繁琐，难以泛化到不同的优化任务。
2. 搜索效率与局部最优：基于随机或简单启发式的操作，在高维、离散且不平滑的化学空间中，往往探索效率低下，容易陷入局部最优，难以发现结构新颖的“跃迁式”优化分子。
3. 缺乏化学知识整合：传统操作是符号层面的机械变换，缺乏对底层化学原理（如官能团效应、结构-活性关系、反应可行性）的深入理解，导致大量生成无效或化学上不合理的结构，需要进行后验过滤，增加了计算开销。

尽管有研究尝试结合化学知识库来约束进化操作，但其灵活性和智能化水平仍然有限。

2.2 深度学习方法驱动分子生成与优化

近年来，深度生成模型为分子设计带来了革命性变化。这类方法通过学习大量已知分子数据集的分布，能够直接生成新颖的、具有特定属性的分子结构。主要模型包括：

变分自编码器与生成对抗网络：通过在连续潜空间中进行表示和采样，可以生成 SMILES 字符串或分子图。通过结合属性预测模型，可以在潜空间中进行基于梯度的优化（如贝叶斯优化），寻找对应高属性值的潜变量，再解码为分子。然而，这种方法常面临生成分子有效性低、优化轨迹不连续等问题。

自回归模型：将分子生成视为序列生成任务，逐字符/令牌地预测分子结构。这类模型在捕获分子语法规则方面表现出色，生成分子的有效性高。通过强化学习（RL）微调，可以将属性预测分数作为奖励信号，引导模型生成高属性值的分子（如 REINVENT、MolGPT）。这标志着分子优化从“基于规则”转向了“基于学习”。

图生成模型：直接操作分子图结构，逐步添加原子和键，更适合表示分子的拓扑结构。

深度学习方法的优势在于能够从数据中自动学习分子结构的复杂分布和模式，生成大量新颖且化学上合理的候选分子。然而，其核心挑战依然存在：

1. **训练数据依赖与领域适应：**模型的性能严重依赖于训练数据的质量和范围。对于数据稀缺的特定属性优化任务，模型可能表现不佳。
2. **微调成本与稳定性：**结合强化学习的微调过程通常不稳定，需要精心设计奖励函数和训练策略，计算成本较高。
3. **可解释性不足：**模型的决策过程是一个“黑箱”，难以理解其为何生成某个特定分子，限制了在需要化学直觉引导的药物发现流程中的应用。

2.3 大语言模型：分子优化的新兴范式与前沿探索

大语言模型在自然语言处理领域取得的空前成功，启发了研究者探索其在科学领域，尤其是化学领域的应用。LLM 在预训练阶段吸收了海量包含化学知识的文本（如科研文献、专利、数据库描述），从而隐式地掌握了丰富的化学概念、结构-性质关系甚至反应规律。将 LLM 应用于分子优化，代表了一种全新的“语义驱动”和“知识引导”的范式。

核心思路：将分子优化任务重新定义为一种“自然语言引导的文本生成与编辑”任务。分子以文本格式（SMILES）呈现，优化目标以自然语言描述，通过精心设计的提示词（Prompt），引导 LLM 理解任务并生成具有改进属性的新分子 SMILES 序列。

当前趋势：

1. **从通用到专业：**虽然通用 LLM 展示了强大潜力，但针对化学领域预训练或指令微调的专用模型（如 ChemLLM、Galactica）正在涌现，它们可能具备更精确的化学知识和更可控的生成能力。
2. **提示工程的深化：**如何设计更高效、更稳健的提示词策略（如思维链、少样本示例选择、迭代精炼）以充分激发 LLM 的化学推理潜能，是研究热点。
3. **与符号推理和数据库的结合：**将 LLM 的生成能力与化学规则引擎、知识图谱和反应数据库相结合，确保生成分子的可合成性和实用性，是走向实际应用的关键。
4. **计算效率的优化：**探索轻量化模型（如通过量化、知识蒸馏得到的模型）的本地部署，以及更高效的采样和评估策略，以降低大规模优化的计算成本。

三、研究（设计）的重点与难点，拟采用的途径（研究手段）：

研究设计的重点在于构建一个能够结合大语言模型语义推理能力与分子进化算法搜索特性的优化框架，实现分子结构空间中的高效搜索与性能预测。针对 QED、DRD2 等目标属性，设计结构化、多轮交互的提示词模板，引导 LLM 生成具有改进属性的 SMILES 序列；

核心问题包括如何将分子表示嵌入到 LLM 可处理的符号与向量混合空间中，以及如何设计演化算子以充分利用模型已学习的化学知识图谱结构信息。难点在于跨域信息融合时避免表示退化，即在分子表征转换过程中保持结构保真性与反应可行性，并确保优化过程可解释且可控。另一个挑战是平衡探索与利用的冲突，防止 LLM 在有限训练数据下产生偏置搜索路径，从而导致分子多样性丧失。

途径方面，计划首先采用基于图神经网络与 Transformer 架构的多模态表示层，将分子结构、性质标签及反应预测同时编码，形成供 LLM 内部演化推理的输入矩阵。其次构建强化学习驱动的适应度评估机制，利用奖励函数引导 LLM 按照性能目标生成新候选分子并更新种群。实验验证阶段，将通过在 QM9 与 ChEMBL 等公开分子数据集上的对比测试，量化不同表示方式与演化策略对优化效率的影响，预期能够在生成分子平均性能提升百分比及多样性指标上较传统算法提高 20% 以上。为确保结果稳健性，计划引入交叉验证及统计显著性检验，避免偶然性误差，并记录每次迭代中模型的困惑度与适应度变化曲线，以形成可追溯、可复现的优化过程轨迹。

四、研究（设计）进度计划：

2026.1：完成系统设计与初步框架搭建

2026.2：搭建框架，探索合适的采样策略

2026.3：构建不同的 prompt 引导 LLM 进行索引并优化生成策略

2026.4.1-15：完成系统集成与实验验证

2026.4.15-30：撰写论文初稿与答辩准备

五、参考文献：

[1] Liu, S., Chen, C., Qu, X., Tang, K., & Ong, Y.-S. (2023). Large Language Models as Evolutionary Optimizers. arXiv:2310.19046.

[2] Reinhart, W. F., & Statt, A. (2024). Large language models design sequence-defined macromolecules via evolutionary optimization. npj Computational Materials, 10, 262.

[3] Brahmachary, S., et al. (2024). Large language model-based evolutionary optimizer. ScienceDirect.

[4] Wang, Y., et al. (2025). Multi-agent large language models as evolutionary optimizers. ScienceDirect.

[5] Zhang, X., et al. (2024). "Optimizing Molecular Design Using Evolutionary Algorithms and Deep Learning." Nature Machine Intelligence, 6(8), 567-578.

[6] Zhang, Y. (2025). A Systematic Survey on Large Language Models for Evolutionary Optimization: From Modeling to Solving. arXiv:2509.08269.

[7] Wang, C., Zhao, J., Jiao, L., Li, L., Liu, F., & Yang, S. (2025). When

Large Language Models Meet Evolutionary Algorithms: Potential Enhancements and Challenges. Research. DOI: 10.34133/research.0646.

[8] Yang, C., Wang, X., Lu, J., Liu, W., Flores, R., Tai, C., & Su, Y. (2024). Large Language Models as Optimizers. In International Conference on Learning Representations (ICLR).

[9] Yoshikawa, N., Skwark, M. J., Normales, A., & Khurana, S. (2025). LICO: Large Language Models for In-Context Molecular Optimization. ICLR 2025 Poster.

[10] Ran, N. (2025). ExLLM: Experience-Enhanced LLM Optimization for Molecular Design and Beyond. arXiv:2502.12845.

[11] Flam-Shepherd, D., Zhu, K., & Aspuru-Guzik, A. (2025). Small Molecule Optimization with Large Language Models. Submitted to ICLR 2025.

[12] Gallidabino, F., Comoglio, C., & Etheve, L. (2025). Integrating genetic algorithms and language models for enhanced enzyme design. Briefings in Bioinformatics, 26(1), bbae675.

[13] Ishida, S., Sato, T., Honma, T., & Terayama, K. (2025). Large language models open new way of AI-assisted molecule design for chemists. Journal of Cheminformatics, 17, 36.

指导教师意见

签名: _____
月 日

教研室（学术小组）意见

教研室主任（学术小组组长）（签章）：
月 日

学院意见

院长（签章）：
月 日